Kafes-Kuantize Çarpımsal Ağırlıklar: Çevrimiçi Doğrusal Bir Öğrenici Kaç Bite İhtiyaç Duyar?

Lattice-Quantized Multiplicative Weights: How Many Bits Does an Online Linear Learner Need?

Muhammed Ökmen
Bağımsız Araştırmacı / Independent Researcher
ORCID: 0009-0002-9709-966X

Teknik rapor — taslak 4 Eylül 2026

Abstract (EN)

We study multiplicative-weights (MWU/Hedge) online linear classification when the **dual variable** $\theta = \ln w$ is constrained to an integer lattice $\delta\mathbb{Z}$ and to a bounded box, so that every weight is a power of two and every update is an integer increment — a bit shift. The learner keeps **no floating-point master copy, no optimizer moments and performs no backward pass**; its entire state is $4{+}k$ integer bits per synapse. **Theory.** We give a regret bound $\mathbb{E}[L] \le c(\delta)L_j + c(\delta)\ln D/\eta$ with $c(\delta) = \delta/(1-e^{-\delta})$, in which the lattice spacing δ and the effective learning rate $\eta = p\delta$ are decoupled via Bernoulli stepping. Two consequences are sharp: (a) refining the lattice recovers the optimal $\sqrt{2T\ln D}$ rate, but **at fixed $\delta = \ln 2$ the bound is only constant-competitive, so pure `1<<k` and no-regret cannot be had simultaneously**; (b) an **exactness lemma** for the residual accumulator, $\tilde\theta_t := \theta_t + \rho_t \Rightarrow \tilde\theta_{t+1} = \tilde\theta_t - \eta g_t$ with $|\rho_t| < \delta$, shows that the *box* is not a limitation the theory fails to cover but precisely the thing error feedback repairs. We further derive a bit-width law $B^\star \gtrsim \frac{1}{2}\log_2 U$ where $U = M\cdot A/D$ is the **per-coordinate update count** — the total horizon T is the wrong variable, and we refute the T-form experimentally. **Empirics (5 real corpora + synthetic, paired tests).** On four sparse real tasks (three 20 Newsgroups splits and RCV1) a **4-bit** learner is statistically indistinguishable from a validation-tuned FP64 MWU. Against Warmuth's *published* algorithm the integer learner is **at worst tied and wins on two benchmarks** ($+1.82$, $t{=}4.57$ vs fixed-η MWU; $+0.98$, $t{=}3.22$ vs his own $c/\sqrt{t}$ schedule). A **4-bit counter plus a 3-bit integer residual accumulator (7 bits total) matches a 65-bit float-master learner** on dense data (-1.11, $t{=}-2.28$), a $9.3\times$ state reduction; at 8 bits it is *more stable* than the master (±0.20 vs ±0.61). **Negative results — the most useful part of this work.** (i) Two claimed victories were destroyed by our own controls: one by a broken majority baseline, one by a 1.78×10^{-15} lookup-table difference. (ii) We measure the resulting **chaos band** and find it is *not a constant*: 0.90 points on 20 Newsgroups but **4.53 points on MNIST**, so the apparent MNIST gap is **below the minimum detectable effect** and no claim can be made there. (iii) Seven interventions failed to close that gap, and a diagnostic shows the model uses only **9 weight levels** regardless of bit width. (iv) The choice of Bregman potential (Euclidean / p-norm / entropy) made **no measurable difference anywhere**. **Novelty.** We state plainly that **no contribution here is verified as novel**: Winnow2 with $\alpha{=}2$ (1988), the fixed-β Weighted

Majority bound (1994), logarithmic-number-system training (NVIDIA, 2022), 8-bit optimizer state, error feedback and AdaGrad all precede us, and our literature search was **not exhaustive**. What we offer is a controlled measurement with its boundaries mapped.

Özet (TR)

Çarpımsal ağırlık güncellemesinin (MWU/Hedge) **dual değişkeni** $\theta = \ln w$ tamsayı kafesine $\delta\mathbb{Z}$ ve sınırlı bir kutuya hapsedildiğinde ne olduğunu inceliyoruz. Bu kısıt altında her ağırlık ikinin kuvveti, her güncelleme bir tamsayı artışı — yani bir **bit kaydırma** — olur. **Ana ölçüm:** 20 Newsgroups gerçek metin verisinde **4 bitlik işaretli-üs** öğrenici, validation'da ayarlanmış FP64 MWU'dan **istatistiksel olarak ayırt edilemiyor** (90.44 ± 0.46 vs 90.31 ± 0.46). Durum belleği 16× küçük, sıfır float çarpma, sıfır çalışma-zamanı `exp()`. **Ana uyarı:** hiçbir yerde MWU'yu **yenmedik**. Bütün lehte görünen karşılaştırmalar beraberlik. Görünen tek "zafer" ölçüm gürültüsü çıktı.

Uyarı. TASLAK v1 GENELİNDE GEÇERLİ UYARI (2026-09-04, BULGU Iki Iddia Iki Baseline). Bu taslaktaki **tüm Warmuth referansları ALT SINIRDIR.** D-285'te baseline'a (a) genişletilmiş η ızgarası (0.005–4.0) ve (b) **koordinat başına azalan adım programı** $\eta_i = c/\sqrt{n_i}$ verildiğinde, Warmuth'un kendisi üç tezgâhta birden yükseldi: MNIST **+3.2**, yoğun sentetik **+2.3**, 20NG **+1.2** puan. **Ayrıştırma (aşırı düzeltmeden kaçınmak için):** dar η ızgarasının etkisi **yalnızca MNIST'te** gerçektir (+2.4); 20NG (-0.1) ve yoğun sentetikte (-0.25) eski baseline zaten yeterince güçlüydü. Ayrıca D-274..283'te **bizim kolumuzda da program yoktu**, yani eşleşme vardı. **İKİ AYRI İDDİA, İKİ AYRI KIYAS:** *(A) temsil iddiası* — "aynı kural, 4 bit vs 64 bit" — iki kol **program dahil** eşleşmeli (W3). *(B) sistem iddiası* — "motorumuz Warmuth'un yayınlanmış algoritmasını geçer" — baseline W1/W2 olmalı. **W3 Warmuth değil, MWU+AdaGrad'dır** (Duchi ve ark. 2011).

Kıyas	MNIST	Yoğun	20NG
vs **W1** (Warmuth, sabit η)	**+1.82, t=4.57** (önde)	+1.27	+0.30
vs **W2** (Warmuth, kendi $c/\sqrt{t}$)	−1.18	−0.91	**+0.98, t=3.22** (önde)
vs W3 (MWU + AdaGrad)	−1.36	−0.99	−0.90

Düzeltilmiş ana ifade: *4+k bit tamsayı durumla, Warmuth'un yayınlanmış her hâline karşı en kötü berabere, iki tezgâhta önde; MWU+AdaGrad'a karşı 2/3 berabere, MNIST'te geride.* Ayrıca **veri seti çeşitliliği** n=1 → n=5'e çıkarıldı (RCV1 ve MNIST dahil); 4-bit motor 4/5 gerçek görevde berabere, MNIST'te gerçek kayıp. Bu bölümler taslak v2'ye yazılacak.

Giriş

Littlestone, Kivinen ve Warmuth'un kurduğu çerçeve, çevrimiçi öğrenmenin tamamını tek bir denkleme indirger [1,2,3]:

$$w_{t+1} = \arg\min_{w} \Big\{ \eta \langle \nabla L_t, w \rangle + D_\phi(w, w_t) \Big\} \quad \Longleftrightarrow \quad \nabla\phi(w_{t+1}) = \nabla\phi(w_t) - \eta \nabla L_t$$

$\phi = \frac{1}{2}\|w\|^2$ seçilirse gradyan inişi, $\phi = \sum_i w_i \ln w_i$ seçilirse MWU/EG doğar. İkinci durumda dual değişken $\theta_i := \ln w_i$ olur ve güncelleme **dual uzayda basit bir çıkarmaya** iner:

$$\theta_{t+1} = \theta_t - \eta g_t$$

Bu makalenin sorusu şu: bu çıkarma $\mathbb{R}$'de olmak zorunda mı? θ'yı $\delta\mathbb{Z}$ kafesine oturtursak, $\delta = \ln 2$ seçimiyle $w_i = 2^{k_i}$ olur; dual çıkarma **tamsayı artışı**, primal güncelleme **bit kaydırma** haline gelir. Çıkarımda tek bir kayan nokta çarpması ve tek bir aşkın fonksiyon kalmaz — sadece tablo okuma ve tamsayı toplama. Soru pratikte şuna indirgenir: **sinaps başına kaç bit yeter?**

Algoritma

Çift ray (dual-rail)

Her koordinat için iki sayaç $c_i^+, c_i^- \in \{0, \dots, 2^B - 1\}$, ağırlık $w_i = \phi(c_i^+) - \phi(c_i^-)$ ve

$$\phi(s) = \begin{cases} 0 & s = 0 \quad \text{(ölü sinaps)} \\ 2^{\,s-1} & s \geq 1 \end{cases}$$

Hata anında aktif koordinatlarda bir ray $+1$, diğeri -1 kayar (kırpmalı). Maliyet: $2B$ **bit/sinaps**.

Tek ray + işaret (signed-rail)

Bir işaret biti $s_i \in \{+1, -1\}$ ve bir üs $e_i \in \{0, \dots, 2^{B_e} - 1\}$:

$$\phi(s, e) = \begin{cases} 0 & e = 0 \\ s \cdot 2^{\,e-1} & e \geq 1 \end{cases}$$

Hata anında, yön d için: $e{=}0 \Rightarrow (e{\leftarrow}1, s{\leftarrow}d)$; $s{=}d \Rightarrow e{\leftarrow}\min(E_{\max}, e{+}1)$; $s{\neq}d \Rightarrow e{\leftarrow}e{-}1$. Sıfır geçişi doğal: $+1 \to 0 \to -1$. Maliyet: $B_e + 1$ **bit/sinaps**. Aynı net seviye sayısı için çift raydan ~1.7× ucuz.

Stokastik kafes adımı

Kafes $\delta = \ln 2$'de **sabit** kalır (bit kaydırma korunur), ama adım olasılıksal atılır: her aktif sayaç p olasılıkla kayar. Böylece efektif öğrenme oranı $\eta = p\delta < \delta$ olur — **kaba kafeste ince öğrenme oranı**.

Teori

Teorem 1 (Kafes-Hedge sınırı)

D uzman, kayıplar $\ell_{t,i} \in [0, 1]$. Güncelleme $\theta_{t+1,i} = \theta_{t,i} - \delta B_{t,i}$, burada $B_{t,i} \sim \text{Bernoulli}(q_{t,i})$, $q_{t,i} = \frac{\eta}{\delta}\ell_{t,i}$, $\eta \leq \delta$. O zaman her j için

$$\mathbb{E}[L_{\text{alg}}] \;\leq\; c(\delta)\, L_j \;+\; c(\delta)\, \frac{\ln D}{\eta}, \qquad c(\delta) := \frac{\delta}{1 - e^{-\delta}}$$

İspat. $W_t = \sum_i w_{t,i}$, $p_{t,i} = w_{t,i}/W_t$, $\kappa := (1 - e^{-\delta})\eta/\delta$.

$$\mathbb{E}[W_{t+1} \mid \mathcal{F}_t] = \sum_i w_{t,i}\big[(1 - q_{t,i}) + q_{t,i}e^{-\delta}\big] = W_t\big[1 - \kappa\langle p_t, \ell_t\rangle\big] \leq W_t e^{-\kappa\langle p_t, \ell_t\rangle}$$

Bernoulli olduğu için $\mathbb{E}[e^{-\delta B}]$ **tam** hesaplanır; klasik ispattaki Hoeffding lemmasına gerek kalmaz. $Z_t := W_t \exp(\kappa \sum_{s<t} \langle p_s, \ell_s \rangle)$ bir süpermartingaldir, dolayısıyla $\mathbb{E}[Z_{T+1}] \le Z_1 = D$. Alttan $Z_{T+1} \ge \exp(-\delta \sum_t B_{t,j} + \kappa L_{\text{alg}})$ ve Jensen ile $\mathbb{E}[\delta \sum_t B_{t,j}] = \eta L_j$ kullanılırsa $\ln D \ge -\eta L_j + \kappa\, \mathbb{E}[L_{\text{alg}}]$. $\eta/\kappa = c(\delta)$ ile düzenlenir. ■

ÖZGÜNLÜK UYARISI. $p = 1$ (deterministik) özel durumunda bu sınır, Littlestone–Warmuth'un sabit-β Weighted Majority sınırının ve Vovk/Freund–Schapire Hedge sınırının **birebir aynısıdır** ($\beta = e^{-\delta}$ ile). **Bu kısım yeni değildir, ders kitabı sonucudur** [2,4,5]. Yeni olabilecek tek bileşen, kafes aralığı δ ile efektif öğrenme oranı η'nın Bernoulli adımıyla **ayrıştırılması** ve çarpımsal sabitin yalnızca δ'ya, toplamsal terimin yalnızca η'ya bağlı çıkmasıdır. Bunu literatürde bulamadık — ama tarama kapsamlı değildi (§7).

Sonuç 1 (Oran korunur, ama kafes incelmek zorundadır)

$c(\delta) = 1 + \frac{\delta}{2} + O(\delta^2)$ olduğundan, $\eta = \delta$ ile

$$\text{Regret} \le \tfrac{\delta}{2} T + \frac{\ln D}{\delta} \xrightarrow{\delta^\star = \sqrt{2 \ln D / T}} \text{Regret} \le \sqrt{2T \ln D}$$

Sonuç 2 (NEGATİF — sabit kafes sıfır-pişmanlık veremez)

δ sabitse (saf bit kaydırma, $\delta = \ln 2$), $c(\ln 2) = 2 \ln 2 \approx 1.386$ ve

$$\text{Regret} \le 0.386\, T + 2 \ln D$$

Bu T'de lineerdir, yani sıfır-pişmanlık DEĞİLDİR. Saf `1<<k` motoru yalnızca **sabit-rekabetçidir**. Optimal orana ulaşmak için $\delta \to 0$ gerekir, ama $\delta \neq \ln 2$ ise ağırlıklar ikinin kuvveti olmaz ve "bit kaydırma" özelliği kaybolur (tamsayı durum + LUT ve sıfır float çarpma yine korunur).

Saf bit-shift ile sıfır-pişmanlık aynı anda elde edilemez.

Sonuç 3 ($B^\star$ yasası) — ham hali çürütüldü, düzeltilmiş hali ayakta

$\theta^\star$'ın açıklığı $R \approx \ln(D/k)$, basamak sayısı $N = R/\delta^\star$:

$$B \;\ge\; \tfrac{1}{2} \log_2 T \;+\; \log_2 \ln \tfrac{D}{k} \;-\; \tfrac{1}{2} \log_2 (2 \ln D) \implies B \ge \tfrac{1}{2} \log_2 T + 0.53$$

Uyarı. T-hali D-282'de ÇÜRÜTÜLDÜ. T sabit tutulup yalnızca yoğunluk değiştirilince $B^\star$ **5'ten 7'ye** çıktı; $\log_2 T$ ekseninde R^2=0.099. **Doğru değişken koordinat başına güncelleme sayısıdır:**

$$B^\star \;\gtrsim\; \tfrac{1}{2} \log_2 U + 2.6, \qquad U = M \cdot \tfrac{A}{D}$$

T sabitken ölçülen eğim **0.518**, R^2=0.861 (teori 0.50). Uydurmaya girmemiş iki noktada sağlama tuttu: yoğun sentetik $U \approx 280-460 \to$ tahmin 6.6–7.0, **ölçülen 7**; gerçek 20NG U=2.2 $\to$ tahmin 3.15, **ölçülen 3**. **Kanıt gücü sınırlı:** $B^\star$ tamsayı ve yalnızca $\{5, 6, 7\}$; 8 nokta, 3 tohum; üç konfigürasyon eşiği geçemediği için dışlandı.

Pratik okuma (düzeltilmiş): *toplam veri değil — sinaps başına düşen güncelleme sayısı 4 katına çıktığında 1 bit ekle.*

Deneysel protokol

Bu çalışmanın ilk turu (Deney 273) **çürütüldü**; kusurları ve düzeltmeleri kayda geçiriyoruz çünkü metodolojik ders sonucun kendisinden değerli:

İlk turdaki kusur	Düzeltme
Veri %87 tek sınıf; kukla taban %86.73, "zafer" %89.40	**Dengeli veri:** gerçek sette taban %55.15, sentetikte %50.08
Yalnızca sentetik veri	**Gerçek veri:** 20 Newsgroups `comp.*` vs `rec.*`
Tek tohum	**5 tohum**, eşleşmiş t-testi + McNemar
Baseline'a keyfî η=0.5, taranmamış	η **validation'da** 8 değerde taranıyor

Ek sıkılaştırmalar: 20NG başlık/altbilgi/alıntı çıkarıldı (bilinen sızıntı); vektörleştirici yalnızca train'de fit edildi; hiperparametreler yalnızca validation'da seçildi, test setine bir kez bakıldı; MWU log-uzayında uygulandı (taşma ve $w^+ - w^-$ iptal hatası kalkar — baseline'ı güçlendirir). **Veri.** (a) 20 Newsgroups, ikili BoW, D=10^4, 5325 train / 3545 test, ~44 aktif özellik/doküman. (b) Sentetik dengeli: D=10^4, k=20 (10 artı / 10 eksi işaret), aktivasyon p=0.1 (~1000 aktif/örnek), %5 etiket gürültüsü, 12000 train / 3000 test.

Sonuçlar

Ana karşılaştırma (D-274)

Gerçek veri — 20 Newsgroups (çoğunluk tabanı %55.15)

Model	test acc%	F1	çevrimiçi hata
Çoğunluk (sıfır zekâ)	55.15 ± 0.00	0.711	—
Perceptron (toplamsal)	**90.37 ± 0.14**	0.911	**514.4**
Warmuth MWU ($\eta^\star$)	90.31 ± 0.46	0.912	526.6
Bit-shift 4-bit çift ray	90.00 ± 0.23	0.908	550.8
QuantMWU ($B^\star, \eta^\star$)	89.95 ± 0.48	0.908	535.4

Bit-shift vs MWU: −0.31 puan, t= − 1.03, McNemar p=0.159 → **berabere**. **Gerçek metinde çarpımsal makine karşılıksız:** sade toplamsal Perceptron tepede ve en kararlısı. **Dengeli sentetik** (çoğunluk tabanı %50.08)

Model	test acc%	F1	çevrimiçi hata
Çoğunluk	50.08 ± 1.23	0.132	—
Perceptron	61.12 ± 1.42	0.596	4068.6
Warmuth MWU ($\eta^\star$)	75.80 ± 1.21	0.753	2876.6
Bit-shift 4-bit çift ray	**52.17 ± 0.32**	0.439	4564.2
QuantMWU ($B^\star, \eta^\star$)	75.95 ± 1.46	0.762	2827.6

Bit-shift vs MWU: −23.63 puan, t= − 49.27, $p < 10^{-4}$ → **ezici yenilgi**. QuantMWU vs MWU: +0.15, t=0.24, p=0.714 → **tam beraberlik**.

Bit genişliği faz geçişi ($\eta = \ln 2$ sabit)

B (çift ray)	sentetik acc%	MWU'ya fark	gerçek veri acc%
3	51.22	-24.58 ($t=-27.99$)	89.89
4	52.17	-23.63 ($t=-49.27$)	90.00
5	55.25	-20.55 ($t=-37.26$)	90.00
6	**74.72**	-1.08 ($t=-1.24$)	90.00
7–10	74.72 (doygun)	-1.08	90.00

B=5 $\rightarrow$ 6 **arasında keskin faz geçişi.**

Önemli. BU BÖLÜMÜN YORUMU SONRADAN ÇÜRÜTÜLDÜ (D-278, D-280, D-281). Ölçümler doğrudur; yorumu yanlıştı. **(a)** Float master tutan kol, **4 bitlik çıkarımla** yoğun veride %75.27 aldı (Warmuth 75.80). Yani **4 bitlik kafes temsil olarak yeterlidir**; faz geçişi temsilin kapasitesi değil, **tamsayı-saf öğrenmenin** dinamiğidir. **(b)** Doygunluğun mekanizması "kutuya yapışma" değil **simetrik yayılmadır (difüzyon)**: 4 bitte sayaç histogramı düz dolar (her durumda ~670 sinaps), tavandakiler iki uca birden dağılır (+7'de 542, -7'de 601; $|\text{ort}|/\text{std} = 0.016$). **(c)** Belirleyici nicelik aktif özellik sayısı A değil, **kutu genişliği / adım boyu = etkin durum sayısı**; bunun veri tarafındaki karşılığı **koordinat başına güncelleme sayısı** $M \cdot A/D$ (seyrek ~2.4, yoğun ~450). **(d)** Doğru çözüm bit genişliği değil **artık biriktiricidir**: 4 bit sayaç + 3 bit artık = **7 bit**, 65 bitlik float master ile eşit (-1.11, $t=-2.28$). Aynı 7 bit bütçesi 7+0 yerine 4+3 dağıtılınca daha iyi ve daha kararlıdır (74.16±1.27 vs 73.58±1.94).

Tek ray vs çift ray — bit verimliliği (D-275)

Gerçek veri (MWU referans 90.31 ± 0.46)

Temsil	bit	acc%	MWU'ya fark
Tek ray işaret+3	**4**	**90.44 ± 0.46**	+0.12, t=0.61 berabere
Tek ray işaret+4/5/6	5–7	90.44 ± 0.46	doygun, fazlası israf
Tek ray işaret+2	**3**	89.99 ± 0.51	-0.32, $t=-0.92$
Çift ray 4+4	8	90.00 ± 0.23	-0.31
Çift ray 6+6	12	90.00 ± 0.23	-0.31
Çift ray 2+2	4	89.13 ± 0.73	-1.18, $t=-4.40$ **kaybediyor**

Aynı bit bütçesinde tek ray çift rayı geçiyor (4 bit: 90.44 vs 89.13). Doygunluk tam 4 bitte; 5/6/7 bit rakamı virgülüne kadar aynı. **Dengeli sentetik** (MWU 75.80): tek ray 3/4/5/6 bit $\rightarrow$ 51.32 / 52.33 / 53.50 / 57.15; **7 bit** $\rightarrow$ **73.58** (-2.22, $t=-3.27$). Çift ray 12 bit $\rightarrow$ 74.72 (-1.08, berabere). Kuramın öngördüğü basamak-sayısı denkliği gözlendi: tek ray 7 bit (127 seviye) $\approx$ çift ray 12 bit (127 seviye).

Stokastik kafes adımı (D-276)

Dengeli sentetik (MWU 75.80):

Model	p=1	0.5	0.25	0.1	0.05	0.02	ölçülen $p^\star$	tahmin N^2/M
Çift 4+4 (8 bit)	52.17	52.30	52.35	54.19	**54.41**	51.96	0.05	0.049 \{}checkmark
Çift 5+5 (10 bit)	55.25	60.11	**70.67**	61.45	55.81	51.96	0.25	0.273 \{}checkmark
Çift 6+6 (12 bit)	**74.72**	73.61	70.67	61.45	55.81	51.96	1.0	1.000 \{}checkmark
Tek 6 bit	57.06	70.19	**71.17**	62.58	54.97	52.48	0.25	0.269 \{}checkmark
Tek 4 bit	52.14	51.77	52.31	51.97	51.83	51.87	—	0.011 × (düz)

Gerçek veri: her iki modelde de $p^\star = 1$; p düştükçe monoton bozulma (tek 4 bit: 90.76 → 88.98 → 86.75 → 83.22 → 79.15 → 74.36). Seyrek metinde koordinat başına güncelleme sayısı $M \cdot A/D \approx 2.4$ olduğu için doygunluk hiç oluşmuyor. **7 bit + stokastik (D-277):** p=1: 73.58 → p=0.5: 72.00 → p=0.25: 69.87 → p=0.1: 63.91. **Kalan -2.22'lik açık kapanmıyor.**

Tamsayı ile öğrenmek vs float ile öğrenmek (D-278)

BitNet b1.58 gibi kuantizasyon yöntemleri eğitim sırasında **float master ağırlık** tutar (QAT) ve yalnızca ileri geçişte kuantize eder. Bizim motorumuzun durumu **tamamen tamsayıdır**. Fark tam olarak izole edildi: aynı temsil, aynı kafes, aynı kutu, **aynı çıkarım maliyeti** — tek fark dual değişkenin float gölge kopyası.

Kol	Eğitim durumu	Seyrek (20NG)	Yoğun sentetik (4 bit)
Master-float (QAT analoğu)	**64+1 bit**	90.56 ± 0.71	**75.27 ± 0.61**
Tamsayı-saf (bizimki)	**4 bit**	**90.49 ± 0.64**	52.43 ± 0.50
fark	—	-0.07, $t = -0.32$	-22.84, $t = -71.38$

Seyrek rejimde float master gereksizdir (16× eğitim belleği). **Yoğun rejimde kritiktir.**

Öz-düzeltme: master-float **4 bitlik çıkarımla** yoğun veride %75.27 aldı (Warmuth 75.80). Yani §5.2'deki *"yoğun veride 7 bit gerekir"* yorumu yanlıştı: **4 bitlik kafes temsil olarak yeterlidir**; arıza tamsayı-saf öğrenmenin kuantum-altı biriktirememesidir.

Doygunluk yayılmadır, ortak kayma değil (D-280)

Yoğun tezgâhta 4 bitlik sayaç histogramı **düz doluyor**: her durumda ~670 sinaps; tavandakiler **iki uca birden** dağılmış (+7'de 542, −7'de 601; denge 0.902), |ort|/std = 0.016. Gerçek veride tavana yapışan sinaps **sıfır**.

Bu, *"eksik bileşen Bregman normalizasyonudur"* iddiasını çürütür: (a) normalizasyon global pozitif skalerdir, skorun **işaretini değiştirmez**; (b) simetrik bir yayılma sabit bir kaydırmayla düzelmez; (c) kafeste koordinat-başı normalizasyon zaten §2.2'nin tek-ray temsiline indirgenir.

Belirleyici tek nicelik: kutu genişliği / adım boyu = **etkin durum sayısı**.

Tamsayı artık biriktirici: 7 bit ≡ 65 bit (D-281)

k bitlik tamsayı artık r_i; hata anında $r_i \mathrel{+}= d \cdot g$, $|r_i| \geq 2^k$ olunca sayaç 1 kayar ve $r_i \mathrel{-}= \text{sgn} \cdot 2^k$. Efektif adım $p = g/2^k$ — **tam, deterministik, sıfır float, sıfır rastgelelik**.

toplam bit	acc (yoğun)	master'a fark
4 (k=0)	52.14 ± 1.25	−23.13
6 (k=2)	55.28 ± 0.56	−19.99
7 (k=3)	**74.16 ± 1.27**	−1.11, $t=-2.28$
8 (k=4)	**75.13 ± 0.20**	−0.14 (master'dan **kararlı**)

4 bit sayaç + 3 bit artık = 7 bit ≡ 65 bit float master (9.3×)

Bit tahsis kuralı: aynı 7 bit, 4+3 dağıtılınca 7+0'dan iyi ve kararlı (74.16±1.27 vs 73.58±1.94). *Biti sayaca değil biriktiriciye ver.* Aynı deneyde iki düzeltme **öldü**: marj kapısı baseline'dan kötü (51.86), sızıntılı sönümleme etkisiz (52.34).

Beş gerçek veri seti (D-283)

Veri seti çeşitliliği n=1 → n=5: üç farklı 20NG ayrımı + **RCV1** (farklı külliyat) + **MNIST** (farklı kiplik).

Veri seti	çoğunluk	Warmuth	4-bit	fark
20NG din vs ticaret	0.523	0.8893	**0.8900**	+0.07
20NG comp vs rec	0.552	0.9047	0.9027	−0.21
RCV1 CCAT vs rest	0.536	0.8239	0.8179	−0.60
20NG sci vs talk	0.548	0.8217	0.8071	−1.46 ($t=-1.93$, 8 tohum)
MNIST 0-4 vs 5-9	0.514	0.7738	0.7342	−3.96 ($t=-2.52$)

3 tohumda sci-vs-talk farkı −2.37 görünüyordu; **8 tohumda −1.46'ya inip anlamsızlaştı** — §6-N3'ün kuralının bir ön sonucu manşet olmaktan kurtardığı ilk vaka.

Koordinat başına azalan adım programı ve üç yollu kıyas (D-284/285)

Tüm önceki motorlar **sabit** efektif adım kullanıyordu. Azalan program kafeste bedava oturuyor: **biriktiricinin eşiğini kaydır**, $p = 1/2^{k+\text{shift}}$, shift $= \lfloor \log_2 n_i \rfloor // 2$. *Sayaç 4 katına çıkınca eşiği 1 bit kaydır* — Sonuç 3'ün dinamik ikizi, **sıfır bölme sıfır float**. **Baseline'a üç steelman verildi.** Bu ayrım kritiktir ve iki farklı iddiayı ayırır:

Kıyas	Bu kim?	MNIST	Yoğun	20NG
vs W1 — sabit η, geniş ızgara (0.005–4.0)	**Warmuth, klasik**	**+1.82** (t=4.57) **(önde)**	+1.27	+0.30
vs W2 — küresel $c/\sqrt{t}$	**Warmuth, kendi öngördüğü**	−1.18	−0.91	**+0.98** (t=3.22) **(önde)**
vs W3 — koordinat $c/\sqrt{n_i}$	**AdaGrad** [Duchi ve ark. 2011], Warmuth değil	−1.36	−0.99	−0.90

İki ayrı iddia, iki ayrı baseline. *(A) Temsil iddiası* — "aynı kural, 4 bit vs 64 bit" — iki kol **program dahil** eşleşmeli (W3). *(B) Sistem iddiası* — "motorumuz yayınlanmış algoritmayı geçer" — baseline W1/W2. **İkisi de raporlanmalıdır.**

İkinci eksen — maliyet: program bizde **yerleşik** (`bit_length` + kaydırma, tamsayı), W3'te **eklenti** (karekök + bölme, float). W3 yalnızca "Warmuth değil"dir; aynı zamanda **Warmuth'tan pahalıdır**. *(Analitik işlem sayımı; donanımda ölçülmedi.)* **Yan bulgu:** küresel program seyrek veride **ölümcül** (20NG −6.84, $t=-125$) çünkü $U \approx 2.2$ — koordinat başına 2.2 güncelleme varken küresel adım çoktan buharlaşıyor. Koordinat programı aynı yerde sağlam.

MNIST kovalamacası ve kaos bandı (D-286...D-290)

MNIST'teki açığı kapatmak için **yedi müdahale** denendi: daha fazla bit, stokastik adım, artık biriktirici, küresel program, koordinat programı, p-norm çanağı, program sertliği. **Yalnızca koordinat programı işe yaradı (+2.5), açık kapanmadı. Teşhis (D-288):** B=8 kutusunda (S=127) kullanılan aralık yalnızca ±4; $|s|$ dağılımı **[411, 281, 56, 28, 8, 0, ...]** — koordinat başına ortalama **464** güncellemeye rağmen tüm model **9 ağırlık seviyesi** kullanıyor. Bu yüzden B=4, 5, 6, 7, 8, 10 **dört ondalığa kadar birebir aynı** (0.8094). **MNIST'te bit genişliği bağlayıcı kısıt değildir.**

Uyarı. D-290 — kaos bandı ölçüldü ve hükmü geri çektirdi. Matematiksel olarak **özdeş** iki LUT ifadesi (`2.0**k` vs `exp(k·ln2)`, fark 1.78×10^{-15}), aynı tohumlarla:

	MNIST	20NG
Tohum başına max \{}	fark\{}	
Kaos bandı (tohum-içi max sapma)	**4.53 puan**	0.90 puan
Eşleşmiş fark sd	**1.57 puan**	**0.21 puan**
5 tohumda ölçülebilir en küçük fark (MDE)	**1.95 puan**	**0.26 puan**

Kaos bandı bir sabit değildir — veri setine göre 5× değişir. MNIST'te iddia edilen −1.7 puanlık açık **MDE'nin altındadır**; orada ne kayıp ne eşitlik iddia edilebilir. **20NG'de MDE 0.26 olduğu için 0.3–1.0 puanlık farklarımız ölçülebilirdir. Zorunlu kural: her etki, o veri setinin bandıyla karşılaştırılır.**

Altı açık eksiğin kapatılması (D-291...D-293)

(a) MNIST, 25 tohum — sınır onaylandı. MDE 1.95 → **0.52–0.60**:

Model	acc	bize göre	hüküm
BİZ 4+k bit	**0.8026 ± 0.0145**	—	—
W1 Warmuth sabit	0.7982	+0.44 (t=1.51)	berabere
W2 Warmuth $c/\sqrt{t}$	0.8166	−1.40 (t= − 5.54)	gerçek kayıp
W3 MWU+AdaGrad	0.8178	−1.52 (t= − 5.48)	gerçek kayıp

(b) Ψ_q birleşik formülü — ilk kez ölçüldü. Optimal çanak **rejime bağlıdır**: seyrek metinde q=0.75 (0.9131, iki ucu da geçiyor: Öklid 0.9063, entropi 0.9102), seyrek-iğne sentetikte $q \to 1$ (0.7671, monoton, iç nokta yok), yoğun görüntüde q=0.25 (0.8065, ama bandın altında). **Tek mimari, LUT değiştirerek üç rejimi de kapsıyor.** 20NG'de q=0.75 ile W3'e fark −0.25 (t= − 1.15) → berabere. Bu, §5.10'daki *"çanak seçimi hiçbir yerde fark etmiyor"* ifadesini düzeltir: kaba ızgarada fark görünmemişti; doğru form ve ince ızgarada **fark var ve rejime bağlı**. **(c) n_i sayacının bit fiyatı ödendi.** b bitlik doyumlu sayaç: 20NG'de **3 bit yeter → toplam 7 bit** (0.9118, t=1.21); MNIST'te 6–8 bit gerekir (3 bitte −5.02).

Dürüst bit bütçesi: seyrek metinde 7 bit (4 sayaç + 3 güncelleme sayacı) — 64 bite karşı 9.1×. Program kullanılmazsa n_i gerekmez ve bütçe 4 bittir, ama programın kazancı da olmaz.

(d) Kaos bandı, dört veri seti: 20NG **0.90** · RCV1 **1.68** · sentetik **2.60** · MNIST **4.53**. Bant 5× aralıkta değişiyor. Sentetikteki 2.60, §5.3'ün 7-bit −2.22'sini **marjinal** yapar; D-278 (−22.84)

ve D-281 (+22) banttan 8–9× büyük ve **sağlam**. **(e) İkili olmayan özellik — en riskli test, GEÇTİ.** 20NG TF-IDF (gerçek değerli x), motor $r_i \mathrel{+}= d \cdot \mathrm{round}(8x_i)$ ile hâlâ tamsayı:

Model	acc
MWU (gerçek değerli, 64 bit)	0.9160 ± 0.0038
BİZ (4+k bit, tamsayı)	**0.9111 ± 0.0049** (-0.49, $t = -2.24$) berabere

İddia ikili girdiye bağlı değildir. $w{=}2^k$ olduğu için $w \cdot x$ hâlâ x'in üssünde kaydırmadır.

Negatif sonuçlar

Bu bölümü çalışmanın **en değerli kısmı** sayıyoruz.

N1 — Hiçbir yerde MWU'yu yenmedik

İki veri setinde, beş tohumda, on'dan fazla konfigürasyonda MWU'ya karşı **hiçbir istatistiksel üstünlük** bulunamadı. Lehte görünen her karşılaştırma beraberliktir.

N2 — Görünen tek "zafer" ölçüm gürültüsüydü

Bir ara raporda "4-bit motor %90.76 ile FP64 MWU'nun %90.31'ini geçti" iddiası oluştu. Kontrol: **matematiksel olarak özdeş** iki uygulama — LUT'u `exp(i·ln2)` ile mi `2.0**i` ile mi kurduğunuza göre — arasında fark 1.78×10^{-15}.

tohum	LUT=`exp(i·ln2)`	LUT=`2**i`	MWU
0	89.87	**91.14**	90.04
1	90.94	90.97	91.20
2	89.99	**91.31**	90.18
3	90.97	90.69	90.27
4	90.41	89.70	89.87
ort.	**90.44 ± 0.46**	**90.76 ± 0.57**	**90.31 ± 0.46**

10^{-15}'lik bir yuvarlama farkı tohum başına **1.3 puana** kadar oynama üretiyor (t=0.79, anlamsız). **İddia geçersizdir.**

N3 — Çevrimiçi öğrenme kaotiktir; tek tohumlu kıyas geçersizdir

Birebir aynı MWU kodunun yalnızca `float32` ve `float64` sürümleri, 3000 adımda tahminlerin %1.5–9'unda ayrışıyor; ilk ayrışma 5.–201. adımda başlıyor.

η	fp32 vs fp64 uyum	ilk ayrışma adımı
0.10	%90.88	31
0.50	%94.62	9
$\ln 2$	%95.75	201
1.00	%97.62	5
2.00	%98.50	46

Sebep: skorun sıfıra çok yakın olduğu bir beraberlikte 1 ULP'lik fark tahmini çevirir; hata-güdümlü öğrenmede tahmin farkı güncelleme farkıdır ve yörüngeler bir daha birleşmez.

N4 — Stokastik adım Pareto sınırını itmiyor

Doymuş genişlikleri kurtarıyor (6 bit: 57.06 → 71.17, **+14.1**) ama 7 bit deterministik (73.58) hâlâ 6 bit stokastikten iyi; 12 bit deterministik (74.72) en iyi kuantize nokta olarak kalıyor.

N4b — Üç algoritma düzeltmesinden ikisi öldü (D-281)

Kendi teşhisimizden türettiğimiz üç düzeltmeden yalnızca biri tuttu.

- **Artık biriktirici (error feedback):** 4+3 = 7 bit, 65 bitlik float master ile eşit (-1.11, $t=-2.28$); k=4'te 75.13 ± 0.20 — master'dan (0.61) **daha kararlı**.
- **Marj kapısı** (gürültülü etiketi reddet): baseline'dan **kötü** (51.86 vs 52.14); validation 4/5 tohumda kapıyı kapattı.
- **Sızıntılı sönümleme:** etkisiz (52.34 vs 52.14); validation 3/5 tohumda kapattı.

Ve bu düzeltmenin kendisi de **özgün değildir**: 8-bit optimizer state (Dettmers, *8-bit Optimizers via Block-wise Quantization*) ve error feedback (Karimireddy ve ark., 2019) mevcut literatürdür. Ölçümümüz literatürün oturduğu yere düştü — **doğrulama, keşif değil.**

N5 — $p^\star \approx N^2/M$ sezgisi evrensel değil

Yoğun rejimde 3/3 isabet (0.049/0.273/1.000 vs ölçülen 0.05/0.25/1.0), seyrek rejimde 0/2. Koordinat başına sayım $M \cdot A/D$ kullanınca seyrek düzeliyor ama yoğun bozuluyor. **İki rejimi birden tutturan form elimizde yok. Bu bir sezgidir, teorem değildir.**

İlgili çalışmalar ve özgünlük beyanı

Uyarı. Bu çalışmadaki bileşenlerin çoğu önceki sanattır. Aşağıdaki liste dürüstlük içindir.

- **Winnow / Winnow2** [1]: Littlestone'un 1988 algoritması çarpımsal günceller; α=2 seçimiyle ağırlıklar ikinin kuvvetidir ve güncelleme **birebir bit kaydırmadır**. §2.1'deki motorumuz, esasen **sınırlı ağırlıklı Winnow2'dir**. Bu 1988 tarihlidir.
- **Weighted Majority / Hedge** [2,4,5]: sabit-β sınırı $(\ln n + m \ln \frac{1}{\beta}) / \ln \frac{2}{1+\beta}$ klasiktir. **Teorem 1'in p=1 hali bu sınırdır.**
- **EG vs GD** [3]: Kivinen & Warmuth'un 1997 makalesi tam olarak toplamsal-vs-çarpımsal kıyasıdır; §5.1'deki Perceptron/MWU karşılaştırması bu literatürün içindedir.
- **LNS-Madam** [6]: logaritmik sayı sistemi + çarpımsal ağırlık güncellemesi, 8 bit, FP32'ye göre %90 enerji tasarrufu. Derin ağ eğitimi, pişmanlık sınırı yok. **Mühendislik tarafında doğrudan önceki sanat.**

- **M+Adam** [7]: çarpımsal güncellemelerin sıfır civarında ve işaret değişiminde başarısız olduğunu raporlar — §2.2'deki işaretli sıfır geçişinin motive ettiği sorun.
- **Stokastik yuvarlama** [8]: yansız düşük-hassasiyet için standart araçtır; logaritmik kuantizasyonda da kullanılmıştır.
- **Uzman probleminde bellek sınırları** [9,10,11]: bellek–pişmanlık ödünleşimi üzerine geniş bir literatür var. Bunlar **kaç uzman saklandığını** sayar; bizim $B^\star$ ifademiz **ağırlık başına kaç bit** olduğunu sorar. Farklı ama komşu.

Aday katkıların tek tek denetimi

İkinci bir hedefli tarama turunda dört aday katkı ayrı ayrı sınandı. Sonuç, ilk taslakta yazdığımızdan **daha olumsuzdur** ve burada düzeltiyoruz:

Aday katkı	Bulunan önceki sanat	Hüküm
(1) Kafes δ ile etkileşimli üçgenlerin Bernoulli ayrıştırması; Teorem 1'in biçimi	Kısmen teknikler mevcut: lazy update prosedürleri, ağırlık toplamını MCMC ile kestirme, fatal mekanizma ile örnekleme [5,13]. Bu **tam ifade** bulunamadı.	**Bulunamadı, düşük güven.** Çarpımsal bir güncellemeyi Bernoulli ile yaneslileştirmek yeterince standart bir tekniktir; ama sunum "folklor" diyebilir.
(2) $B \geq \frac{1}{2}\log_2 T$ bit-genişliği yasası	**Progressive precision** [14]: "her iterasyonda minimizasyon hassasiyetinin optimal kestirildi", "order-optimal regret" — hassasiyetin iterasyonlar boyunca artması gerektiği **aynı kavramdır**. Ayrıca HALP [15] ve düşük-hassasiyet SGD teorisi.	**Kavram yeni değildir.** Bizimki farklı bir kurulumda. (Anal kodu, MWU, piyasanalik) bir örnektir; önceki iddiası **geri çekilmiştir**.
(3) Eşik bit bütçesinde tek ray vs çift ray	Çift ray RG'ye [3]; işaretli logaritmik temsil LNS'ye standartlar [6].	**Altlasyon sonuçudur, keşif değildir.** Tek veri setinde, 5 tohumda paşetli bir mühendislik verisi.
(4) Kayan-nokta hassasının çevrimiçi öğrenmede otopsisi	[16] *Impacts of floating-point* non-associativity on reproducibility *iteratif algoritmalarda yürtüşe ayrışmasını doğrudan belgeler; ayrıca deterministik ML çerçeveleri [17].*	**Yeni değildir.** Fenomen iyi belgelenmiştir; bizimki hata-giderimli çevrimiçi öğrenici için temiz bir gösterimdir.

Uyarı. ÖZGÜNLÜK DOĞRULANMAMIŞTIR VE BU RAPOR BİR ÖNCELİK İDDİASI DEĞİLDİR. Dört aday katkıdan **en fazla biri** (1) yayınlanmamış olabilir, o da düşük güvenle. (2) ve (4) için doğrudan önceki sanat bulunmuştur. Yapılan tarama birkaç hedefli sorgudan ibarettir. **Yapılmamış olanlar:** COLT/NeurIPS/ICML/JMLR proceedings sistematik taraması; Littlestone–Warmuth (1994) ve Kivinen–Warmuth (1997)'den ileri atıf takibi; sınırın tam biçiminin aranması; alan uzmanına danışma.

Bu çalışmanın gerçek değeri nerede

Yukarıdaki denetimden sonra geriye kalan ve savunduğumuz şey bir "yenilik" değil, bir **yöntem**dir: aynı iddia bu programda **iki kez** kuruldu, ikisinde de sayılar gerçekti, ikisi de yıkıldı — önce kırık tartıyla (§4), sonra 10^{-15}'lik yuvarlama gürültüsüyle (§6-N2). §6'daki beş negatif sonuç ve §4'teki protokol, sonuçların kendisinden daha taşınabilirdir.

Sınırlar

- **Model sınıfı:** doğrusal, ikili özellikler, ikili sınıflandırma, çevrimiçi. Derin ağ, çok sınıflı problem, katmanlar arası kredi ataması **yok**.
- **Ölçek:** $D = 10^4$, $T \leq 1.2 \times 10^4$. LLM ölçeğine ekstrapolasyon **desteklenmiyor**.
- **Attention/softmax ile ilgisi yoktur.** MWU'nun exp'i zaman içinde ağırlık güncellemesidir; attention'ın softmax'ı çıkarımda sorgu başına normalizasyondur. Farklı nesnelerdir.
- **Düşük-bit çıkarım yeni değildir** (INT8/INT4, GPTQ, AWQ, BitNet). Buradaki ilgi noktası düşük-bit **öğrenme durumu** ve ona eşlik eden sınırdır.
- **Sonuç 3'ün ampirik desteği iki noktadır.** Yasa değil, çelişmeyen bir türetmedir.
- **Sentetik tezgâh yapaydır**; gerçek veri sonuçları tek bir veri setinden gelir.
- $B^\star$ **ile aktif özellik sayısı** A **arasındaki yasa ölçülmemiştir.** Yoğunluk taraması ($p \in [0.002, 0.2]$) açık iştir.

8b. Ölçüm standardı — kaos bandı (bu çalışmanın yöntemsel çekirdeği)

Hata-güdümlü çevrimiçi öğrenme kaotiktir (§6-N3). D-290 bunu **nicelleştirdi**: matematiksel olarak özdeş iki uygulama, aynı tohumlarla, ne kadar ayrışır?

Tezgâh	eşleşmiş fark sd	**5 tohumda MDE**	bizim tipik etkilerimiz	okunur mu?
20NG	0.21 puan	**0.26 puan**	0.3–1.0	evet
MNIST	1.57 puan	**1.95 puan**	1.7	**hayır**

Kural: hiçbir etki, kendi veri setinin bandıyla kıyaslanmadan raporlanamaz. Bu makaledeki büyük etkiler (-22.84, $+22.0$, ayrık $B^\star$ sıçraması) banttan **20–25 kat** büyüktür ve sağlamdır; MNIST'teki 1.7 ise bandın altındadır ve **hiçbir yön iddia edilmemiştir.**

Sonuç

Warmuth'un evrensel dual denklemi $\theta_{t+1} = \theta_t - \eta g_t$, θ bir tamsayı kafesine hapsedildiğinde de anlamlı kalır ve sabit-rekabetçi bir garanti taşır (Teorem 1); kafes incelirse optimal $O(\sqrt{T \ln D})$ oranı geri gelir (Sonuç 1), ama o zaman saf bit kaydırma özelliği kaybolur (Sonuç 2). Ampirik olarak, gerçek seyrek metinde **sinaps başına 4 bit**, validation'da ayarlanmış FP64 MWU ile beraberliğe yetiyor — 16× durum tasarrufu, sıfır float çarpma, sıfır çalışma-zamanı `exp()`. Yoğun veride 7 bit gerekiyor ve orada bile 2.22 puan geride kalınıyor. Savunulabilir cümle **"Warmuth'u geçtik" değil**, şudur:

Warmuth'un işini, çok daha ucuz bir donanımda, aynı doğrulukla yapıyoruz — ve nerede yapamadığımızı da biliyoruz.

Kaynaklar

1. N. Littlestone. *Learning Quickly When Irrelevant Attributes Abound: A New Linear-threshold Algorithm.* Machine Learning, 1988. — Winnow (özet))

2. N. Littlestone, M. K. Warmuth. *The Weighted Majority Algorithm.* Information and Computation, 1994. — PDF

3. J. Kivinen, M. K. Warmuth. *Exponentiated Gradient versus Gradient Descent for Linear Predictors.* Information and Computation, 1997.

4. Y. Freund, R. Schapire. *A Decision-Theoretic Generalization of On-Line Learning.* JCSS, 1997.

5. S. Arora, E. Hazan, S. Kale. *The Multiplicative Weights Update Method: a Meta-Algorithm and Applications.* Theory of Computing, 2012. — PDF

6. *LNS-Madam: Low-Precision Training in Logarithmic Number System using Multiplicative Weight Update.* — arXiv:2106.13914

7. *M+Adam: Low-Precision Training via Additive–Multiplicative Optimization.* — arXiv:2607.10611

8. S. Gupta, A. Agrawal, K. Gopalakrishnan, P. Narayanan. *Deep Learning with Limited Numerical Precision.* ICML, 2015.

9. *Memory Bounds for the Experts Problem.* — arXiv:2204.09837

10. B. Peng et al. *Near Optimal Memory-Regret Tradeoff for Online Learning.* — arXiv:2303.01673

11. *Online Prediction in Sub-linear Space.* — arXiv:2207.07974

12. *Instance-Optimal Matrix Multiplicative Weight Update and Its Quantum Applications.* — arXiv:2509.08911

Ek A — Tekrarlanabilirlik

Tüm kod ve ham çıktılar kasada:

Dosya	İçerik
`Kodlar/deney_274_temiz_tur.py`	Ana deney (5 tohum, 2 veri seti, 5 model)
`Kodlar/deney_274b_bit_genisligi.py`	$\eta = \ln 2$ sabit, B taraması
`Kodlar/deney_274c_kaos_kontrolu.py`	fp32/fp64 kaos kontrolü (N3)
`Kodlar/deney_274_ham_cikti.txt`	D-274 ham terminal çıktısı

Bağımlılıklar: `numpy`, `scipy`, `scikit-learn` (yalnızca 20NG indirme ve vektörleştirme için). Rastgelelik tohumlanmıştır; §6-N3 gereği sonuçlar kayan-nokta uygulamasına duyarlıdır — **birebir tekrar için aynı NumPy sürümü ve aynı LUT ifadesi kullanılmalıdır.**

Ek B — Deney zinciri

Deney	Rol	Durum
Deney 273	İlk tur	Çürütüldü (kırık tartı)
Deney 274	Temiz tur	
Deney 275	Tek ray vs çift ray	
Deney 276	Stokastik kafes adımı	(Pareto'yu itmedi)
Deney 277	İkinci sahte zaferin otopsisi	
Deney 278	Kamanın izolasyonu	
Deney 279	p-Norm çanağı	(tahmin çöktü)
Deney 280	Doygunluk teşhisi	
Deney 281	**7 bit ≡ 65 bit**	ana ölçüm
Deney 282	T-yasası çürütüldü, U-yasası kuruldu	
Deney 283	n=1 → n=5	
Deney 284	Koordinat programı + üç yollu kıyas	
Deney 286	MNIST kovalamacası (7 müdahale)	hüküm geri çekildi
D-289 / D-290	İnce kafes / **kaos bandı ölçümü**	
TEOREM Kafes MWU	Teorem + 4 sonuç (kutulu rejim dahil)	
BULGU BitShift Bit Genisligi Faz Gecisi	Faz geçişi (yorumu düzeltildi)	
BULGU Cevrimici Ogrenme Kaotiktir	Kaos + bant ölçümü	
BULGU Iki Iddia Iki Baseline	Steelman'in sınırı	

Yıkılan zafer iddiaları (dördü de kendi kontrollerimizle): D-273 kırık tartı · D-277 ULP gürültüsü · D-280 "normalizasyon eksik" · D-284/285 handikaplı baseline. İkisi **ilan edilmeden** yakalandı.

Ek C — Sonuç 4: kutulu rejimde kesinlik lemması

Teorem θ'yı **sınırsız** varsayıyordu; motorumuz ise **kırpıyor**. Bu, uzun süre *"teorem çuvalladığımız yeri kapsamıyor"* diye açık eksik sayıldı. **Çözüm projeksiyonda değil, artık biriktiricide. Lemma A (kesinlik — tam eşitlik).** Artık ρ_t ile sanal yineleme $\tilde{\theta}_t := \theta_t + \rho_t$ tanımla. Taşıma kuralı $\rho_{t+1} = \rho_t - \eta g_t - (\theta_{t+1} - \theta_t)$ olduğundan:

$$\boxed{\tilde{\theta}_{t+1} = \tilde{\theta}_t - \eta g_t}$$

Sanal yineleme, kuantizasyon hiç yokmuş gibi TAM ayna inişi yapar. Yuvarlama hatası kaybolmaz — artıkta saklanır. **Lemma B (sınırlılık).** Taşıma mekanizması $|\rho_t| < \delta$ garantiler; T**'den ve** k**'dan bağımsız. Lemma C (oynanan ağırlık).** $e^{-\delta}\tilde{w}_i \le w_i \le e^{\delta}\tilde{w}_i$ — çarpımsal bozulma **sabit**, büyümez. **Sonuç.** Her karşılaştırmacı $u \in K$ (kutu) için

$$\text{Regret} \;\le\; e^{\delta} \cdot \text{Regret}_{\text{tam MWU}} \;+\; \underbrace{\left[L(\Pi_K u^\star) - L(u^\star)\right]}_{u^\star \in K \text{ ise SIFIR}}$$

Üç ölçümü birden açıklıyor:

Ölçüm	Teorinin dediği
Seyrek: tavana yapışan sinaps **sıfır** (Deney 280)	$u^\star \in K \to$ kutu terimi $0 \to$ 4 bit berabere
Yoğun, biriktiricisiz: histogram **düz doluyor** (D-280)	Lemma A yok $\to$ artık her adım **atılıyor** $\to$ rastgele yürüyüş
Yoğun, biriktiricili: master'a **eşit** (Deney 281)	Kesinlik geri $\to$ sınır tekrar geçerli

Kutu, teoremin kapsayamadığı şey değil — biriktiricinin çözdüğü şey.

Özgünlük: error-feedback çerçevesi bilinendir (Karimireddy ve ark. 2019; Stich & Karimireddy). Kafes-MWU'ya uygulaması yeni olabilir ama **doğrulanmadı ve iddia edilmiyor.** Bu **yapı**dır, satır satır ispat yazılmamıştır; Lemma A tam eşitliktir, B ve C bir satırlıktır, son adım standart Hedge analizidir.